

Tarea 6

Hairo Ulises Miranda Belmonte

May 3, 2019

1 PROBLEMA

a) Realiza un análisis no supervisado para encontrar patrones interesantes en los datos. Para esto, usa las variables que corresponden a las características de audio y otras que consideres adecuadas (por ejemplo, `track.duration`). ¿Puedes identificar los géneros, o al menos, algún subconjunto de ellos?. Obtén visualizaciones apropiadas de baja dimensión. Puedes usar los métodos de visualización y clustering que consideres apropiados, pero incluye spectral clustering. Documenta el procedimiento y hallazgos que encuentres.

b) Considera **audiofeaturesdanceability** y **audiofeaturesenergy** como variables de respuesta. Selecciona un conjunto de entrenamiento y otro de prueba. Para cada variable de respuesta: Construye una variable con 3 categorías (baja, media, alta) a partir de sus valores numéricos

Ajusta clasificadores basados en LDA, QDA, Multilogit y Redes Neuronales, para estimar el nivel de bailabilidad y energía usando el bloque de características de la señal como covariables. Compara los resultados para cada clasificador y documenta tus hallazgos.

c) Estima el nivel de bailabilidad y energía en algunos audios del conjunto de validación que se encuentra en el archivo **my all tracks No genre 2019.csv**. Verifica cualitativamente tus resultados. ¿Te parecen adecuados? (ver Nota 4)

1.1 SOLUCIÓN INCISO "A"

Se realiza análisis no supervisado para encontrar patrones interesantes en los datos; i.e. identificar los géneros de las pistas de audio o algún subconjunto de ellos; se utiliza PCA para obtener representaciones en dos dimensiones; se implementan métodos de *clustering*

como; K-means, Kernel K-means y cluster espectral.

Se hace uso de variables indicadoras que corresponden a las características de audio; acústica, bailabilidad, energía, instrumentalidad, vitalidad, locura, tempo y balance. También, se utiliza la variable "duración de la pista", pensado que puede aportar información para el reconocimiento de algunos géneros.

En la tabla 1.1, se presentan los géneros de las pistas de audio que se encuentran en la base (15 géneros).

Géneros	
Blues	Classical
Country	Easy Listening
Electronic	Experimental
Folk	Hip-Hop
Instrumental	International
Jazz	Old-Time / Historic
Pop	Rock
Soul-RnB	

Table 1.1: Géneros de las pistas de audio

Para realizar PCA y *clustering* se utiliza un subconjunto de datos, debido a la complejidad computacional. Para evitar problemas de este tipo, se utiliza el 20% de la información¹, i.e., 2626 observaciones que son estandarizadas.

En la figura 1.1, se presenta la representación de los datos en dos dimensiones, la figura del lado izquierdo son las dos primeras componentes principales, bajo esta representación se logra observar que existe una ligera tendencia de agrupamiento en el género Hip-Hop (parte superior derecha); en la figura derecha, se implementa K-means -con 15 posibles grupos-, sobre las dos primeras componentes, con esta representación no se logra identificar los géneros; por otro lado, los audios del género rock, se presentan en la mayoría de las agrupaciones que realiza k-means.

¹Se utiliza este porcentaje ya que al implementar cluster espectral se presentaron problemas computacionales; i.e., la RAM de la máquina se saturara; esto ocurrió al utilizar la función **specc** de la librería **Kernlab**, en R, versión 3.5.2; en una maquina con procesador intel core i5, con RAM de 4GB.




Figure 1.1: Primeras dos componentes y K-means clustering

En la figura 1.2, se implementa Kernel K-means sobre las dos primeras componentes; se utiliza un kernel Gaussiano y parámetros sigma de .1 y 10. Se puede observar, que bajo esta representación, no se puede identificar los géneros o algún subconjunto de ellos.



Figure 1.2: Kernel K-means en las dos primeras componentes

En la figura 1.3, se utiliza el método de cluster espectral sobre las dos primeras componentes principales; el kernel que se implementa es Gaussiano con parámetros .1 y 10. Se puede

observar en ambos gráficos, que el género rock se encuentra en casi todos los grupos ; las pistas de audio cuyo género es Hip-Hop, en su mayoría, se encuentran agrupados en la clase 1; sin embargo, no se logra identificar con claridad todos los géneros, ni algún subconjuntos de ellos.

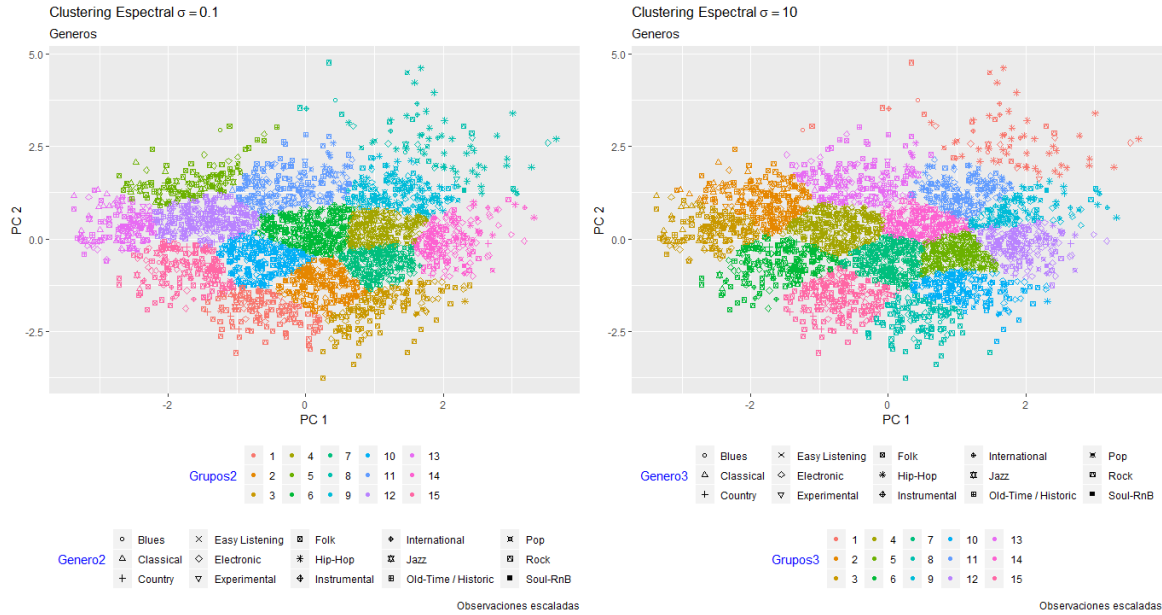


Figure 1.3: Cluster Espectral en las dos primeras componentes

Para mejorar la representación se filtra la base de datos, retirando aquellos audios que puedan causar conflicto en el reconocimiento de patrones interesantes; entre los géneros que se filtraron se encuentran: *Old-Time / Historic*, *internacional*, *Instrumental*, *Experimental* y *Easy Listening*. Los cuales pueden contener audios de otros géneros; por ejemplo, música internacional que sea Rock; Fácil de Escuchar, que contenga algo clásico, entre otros.

Se vuelve a implementar PCA a los datos estandarizados y cluster espectral; en la figura 1.4, se observa las agrupaciones que se realiza al utilizar cluster espectral con 10 categorías y parámetros .1 y 10, sobre las primeras dos componentes; se observa que en ambos casos se logra identificar el subconjunto de género Hip-Hop con mayor claridad; asimismo, en la gráfica de la izquierda con un parámetro de .1, el grupo 5 y 6, concentran a la mayoría de audios de genero clásico.



Figure 1.4: Cluster Espectral en las dos primeras componentes para 10 categorías

En conclusión, al utilizar el subconjunto de observaciones con las características de los audios y la variable del tiempo de duración, y bajo la representación de PCA e implementando métodos de agrupamiento, no se logra identificar con claridad los géneros; no obstante, al utilizar cluster espectral y filtrando algunos géneros, se logra observar patrones interesantes, como subconjuntos de géneros que tienden a agruparse.

1.2 SOLUCIÓN INCISO "B"

Del conjunto de datos anteriores se consideran como respuestas **audio features danceability** y **audio features energy** y se construye una variable con 3 categorías (baja, media y alta) a partir de sus valores numéricos. La clasificación de ambos índices son los siguientes; bajo, si el valor se encuentra entre 0-0.35; medio, si se encuentra entre 0.36-0.65; y alto, si se encuentra entre 0.65-1.

Se utiliza un subconjunto de datos de la base original, dado a la presencia de problemas computacionales ²; se trabaja con el 10% de las observaciones, obteniendo una base con 1313 registros y 549 columnas.

Se realiza la validación en la clasificación para estimar el nivel de bariabilidad y energía en cada audio mediante los clasificadores LDA, QDA, Multilogit y Redes Neuronales; ambos modelos se entrenan con un subconjunto seleccionado de manera aleatoria de la nueva base, con 80% de los datos (1050 filas) como conjunto de entrenamiento, y 20% (263 fila) de los

²Debido a la capacidad y el modelo del computador con el que se realiza el trabajo (intel core i5 con 4GB RAM), se toma un subconjunto de datos pequeño; cabe mencionar que al tomar un porcentaje mayor al 10%, que equivalen a mil o un poco más de dos mil observaciones, al utilizar la función *neuralnet* en R, el proceso demoraba para dar las salidas.

datos restantes se utilizan para probar el clasificador.

Las variables de entrada consisten en características de señales del audio, en las cuales se eliminan algunas de la base de entrenamiento y de prueba con el fin de retirar aquellas cuyo valores permanecen constantes sobre todos los audios; para esto, se estima la varianza de cada variable y se eliminan aquellas con varianzas menores a uno; de esta manera, se reduce el conjunto variables de 549 a 206³.

Los clasificadores se implementan en R versión 5.3.2, se hace uso de distintas librerías y funciones, entre estas las siguientes; para LDA y QDA, se utiliza la librería **MASS** y las funciones **lda** y **qda**; para el clasificador Multilogit, se hace uso de la librería **nnet**, con la función **multinom**⁴; por último, se utiliza la librería **neuralnet** para estimar la red neuronal.

Validación del modelo para estimación de la Bailabilidad

A continuación, se presenta la tabla de confusión para el ajuste de los clasificadores; lo que se espera de estas tablas son una representación de una matriz diagonal, indicando que el clasificador es preciso y clasifica de manera correcta. En las tablas 1.2 a 1.4, se presentan las tablas de confusión para los clasificadores LDA, QDA y Multilogit, ajustados con los datos de entrenamiento, las columnas representan las categorías originales de los audios, y las filas las predichas por el clasificador.

Como se puede observar, solo el clasificador QDA se asemeja a una matriz diagonal, clasificando 290 de 291 audios con bailabilidad baja, 331 de 332 audios con bailabilidad media, y 429 de 427 como bailabilidad alta.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	187	49	6
Medio	75	456	71
Alto	9	49	148

Table 1.2: LDA tabla de confusión; Datos de Entrenamiento

Predichos/ Originales	Bajo	Medio	Alto
Bajo	290	0	0
Medio	0	331	0
Alto	1	1	427

Table 1.3: QDA tabla de confusión; Datos de Entrenamiento

³Vea el archivo **VARIABLES MODELOS.xlsx**, para obtener la lista de covariables con las que se realiza la clasificación.

⁴La función implementa modelos multinomiales log-lineales vía redes neuronales

Predichos/ Originales	Bajo	Medio	Alto
Bajo	172	55	15
Medio	86	448	70
Alto	13	51	140

Table 1.4: Multilogit tabla de confusión; Datos de Entrenamiento

En la tabla 1.5, se presenta el desempeño de los clasificadores que se tiene con los datos de entrenamiento, medido por la tasa de precisión (promedio de las veces que clasifica bien) y la tasa de error (promedio de las veces que clasifica mal). Se observa que el clasificador QDA, presenta una tasa de error cero, seguido del clasificador LDA con tasa de error de 25%, y el Multilogit con una de 28%.

Modelo	Bailabilidad	Tasa de Precisión	Tasa de Error
LDA		75%	25%
QDA		100%	0%
Multilogit		72%	28%

Table 1.5: Desempeño de los clasificadores; Datos de Entrenamiento

Una vez ajustado los clasificadores, se utilizan los datos de prueba para evaluar su desempeño. En las tablas 1.6 a 1.8, se presentan las tablas de confusión para los clasificadores, pero ahora utilizando los datos de prueba; en contraste a los datos de entrenamiento el modelo LDA es el tiende a clasificar mejor.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	37	22	1
Medio	25	101	24
Alto	5	17	31

Table 1.6: LDA tabla de confusión; Datos de Prueba

Predichos/ Originales	Bajo	Medio	Alto
Bajo	1	1	0
Medio	66	139	56
Alto	0	0	0

Table 1.7: QDA tabla de confusión; Datos de Prueba

Predichos/ Originales	Bajo	Medio	Alto
Bajo	36	33	5
Medio	23	88	25
Alto	8	19	26

Table 1.8: Multilogit tabla de confusión; Datos de Prueba

En la tabla 1.9, se presenta la evaluación en el desempeño de los clasificadores con los datos de prueba, donde el modelo LDA reporta la menor tasa de error con 38%, seguido del Multilogit con 42%, y el QDA con 47%. Concluyendo que entre estos tres clasificadores el de mejor desempeño es el LDA.

Modelo	Bailabilidad	Tasa de Precisión	Tasa de Error
LDA		62%	38%
QDA		53%	47%
Multilogit		58%	42%

Table 1.9: Desempeño de los clasificadores; Datos de Prueba

Red Neuronal

Se utiliza una red neuronal para realizar clasificación para validar la estimación de la bailabilidad en las pistas; para esto, se escalan los datos de entrenamiento y de prueba. Para entrenar la red y estimar así los parámetros se utiliza el algoritmo *Resilient back propagation* (*Rprop*)⁵, que es incluida como opción default en la función **nuralnet**.

Se entrenan distintas redes, esto de manera de ejercicio y para obtener un buen clasificador; se utilizan tres redes con una capa oculta, con 3 (Red Neuronal 1) 4 (Red Neuronal 2), 5 (Red Neuronal 3) y 6 (Red Neuronal 4) nodos ocultos, se entrena una Red Neuronal convulsionar con tres capas ocultas, en la primera capa se utilizan 20 nodos ocultos, en la segunda 10 nodos ocultos y en la tercer capa, 3 nodos ocultos, está última solamente con fines didácticos.

Para seleccionar la red con el mejor desempeño para clasificar, se utilizan los criterios **AIC**, **BIC** y cross-entropy multiplicado por cien, de esta forma, queremos valores altos para los primeros dos criterios y bajos para el tercero. En el gráfico 1.5, se presentan los criterios de selección, en el gráfico del lado izquierdo se incluye la Red Neuronal convulsionar, el cual se presenta como la mejor red; sin embargo, se pretende trabajar con una red cuya arquitectura solo tenga una capa oculta, de esta forma, en el gráfico de la derecha solo se encuentran las primeras cuatro redes, y bajo los criterios mencionados se selecciona la Red Neuronal 3 (con

⁵El algoritmo Rprop hace dos cambios sobre el ya conocido back propagation; el primero es que no utiliza la magnitud del gradiente para determinar un peso delta, en vez de eso, utiliza solo el signo del gradiente (se utilizó Rprop+); e segundo es que en vez de utilizar el *learning step* para todos los pesos y sesgos, Rprop mantiene separado los pesos deltas para cada peso y sesgo, y adapta esos deltas durante el entrenamiento.

6 nodos ocultos).

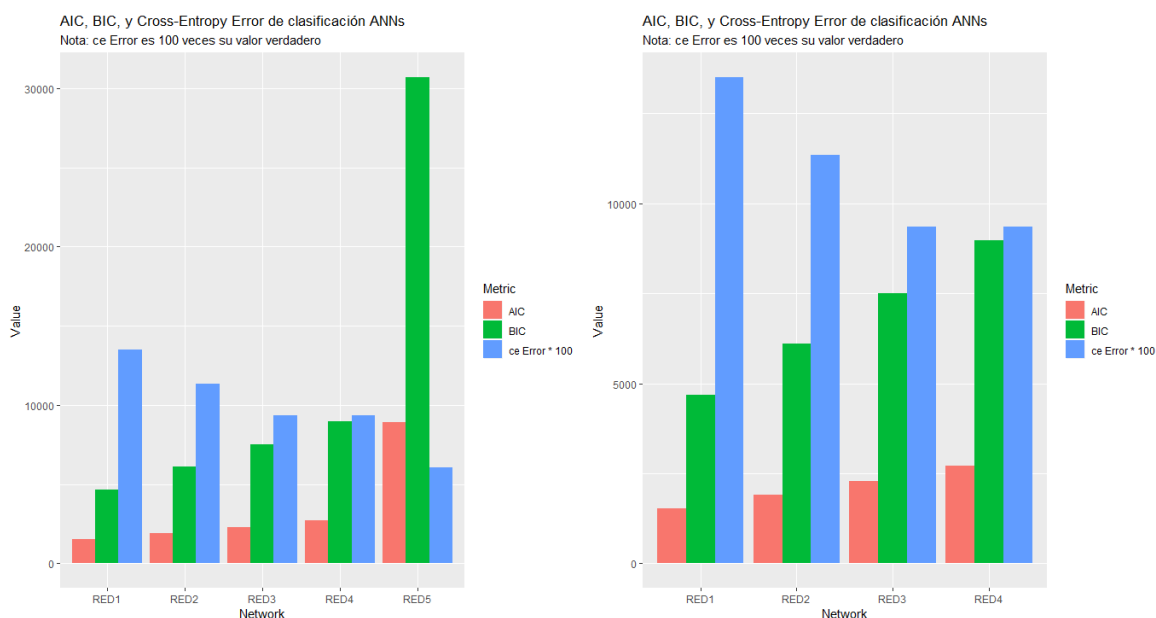


Figure 1.5: Criterios de selección de Red Neuronal

Para poder contrastar contra los clasificadores LDA, QDA y Multilogit, se calcula la tasa de precisión y error, para las 5 redes, podemos ver que el de menor error en clasificación es la Red Neuronal 5, seguida por la Red Neuronal 3, sin embargo, por lo ya mencionado se opta por tomar la Red Neuronal 3.

Modelo	Bailabilidad	Tasa de Precisión	Tasa de Error
Red 1		87%	13%
Red 2		89%	11%
Red 3		90%	10%
Red 4		85%	15%
Red 5		93%	7%

Table 1.10: Desempeño de los clasificadores; Datos de Entrenamiento

En la gráfica 1.6, se visualiza la representación de la Red Neuronal 3, cuya arquitectura consta con 206 nodos de entrada, una capa oculta, 6 nodos ocultos, y 3 nodos de salida l1 (bailabilidad baja), l2 (bailabilidad media) y l3 (bailabilidad alta); cabe mencionar que para todas las redec se utiliza la función de activación logística (sigmoide).




Figure 1.6: Red Neuronal 3

En la tabla 1.11, se presenta la tabla de confusión de la Red Neuronal 3, para los datos de entrenamiento. En la tabla 1.12, se utilizan los datos de prueba y se observa la tabla de confusión, en el cual cuenta con valores fuera de la diagonal, indicando la tendencia a clasificar en grupos equivocados.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	239	8	1
Medio	27	523	41
Alto	5	23	183

Table 1.11: Red Neuronal 3 tabla de confusión; Datos de Entrenamiento

La tabla 1.13, se presenta la tasa de precisión y error de la Red Neuronal 3, utilizando los datos de prueba, con una tasa de error del 48%. En conclusión, el mejor clasificador bajo para estimar el nivel de disponibilidad es el LDA.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	37	49	5
Medio	30	89	41
Alto	0	2	10

Table 1.12: Red Neuronal 3 tabla de confusión; Datos de Prueba

Modelo	Bailabilidad	Tasa de Precisión	Tasa de Error
Red 3		52%	48%

Table 1.13: Red Neuronal 3. Desempeño de los clasificadores; Datos de Prueba

Validación del modelo para estimación de la Energía

Realizamos lo anterior pero ahora en la estimación de la energía que se presentan los audios. La tablas 1.14 a 1.16, muestran las tablas de confusión para los clasificadores LDA, QDA y Multilogit, utilizando los datos de entrenamiento. Se observa que el clasificador LDA, es el que tiene cantidades pequeñas en las diagonales, indicando que clasifica mejor que los otros utilizando los datos de entrenamiento.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	239	18	1
Medio	48	253	54
Alto	4	61	372

Table 1.14: LDA tabla de confusión; Datos de Entrenamiento

Predichos/ Originales	Bajo	Medio	Alto
Bajo	290	0	0
Medio	0	331	0
Alto	1	1	427

Table 1.15: QDA tabla de confusión; Datos de Entrenamiento

Predichos/ Originales	Bajo	Medio	Alto
Bajo	254	31	6
Medio	26	209	49
Alto	11	92	372

Table 1.16: Multilogit tabla de confusión; Datos de Entrenamiento

La tabla 1.17, muestra la tasa de precisión y error, para los clasificadores utilizando los datos de entrenamiento. El clasificador con menor tasa de error es el QDA con 1%, seguido del LDA con 17%, y Multilogit con 21%.

Modelo Energía	Tasa de Precisión	Tasa de Error
LDA	83%	17%
QDA	99%	1%
Multilogit	79%	21%

Table 1.17: Desempeño de los clasificadores; Datos de Entrenamiento

Ahora se utilizan los datos de prueba en los tres clasificadores; las tablas 1.18 a 1.20, presentan las tablas de confusión para cada clasificador, se puede ver que el clasificador LDA de 79 pistas clasificadas como energía baja, clasifica 65, de 85 como energía media clasifica 88, y de 99 de energía alta clasifica 110.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	56	8	1
Medio	19	49	20
Alto	4	28	78

Table 1.18: LDA tabla de confusión; Datos de Prueba

Predichos/ Originales	Bajo	Medio	Alto
Bajo	33	9	1
Medio	14	10	2
Alto	32	66	96

Table 1.19: QDA tabla de confusión; Datos de Prueba

Predichos/ Originales	Bajo	Medio	Alto
Bajo	49	13	2
Medio	23	37	16
Alto	7	35	81

Table 1.20: Multilogit tabla de confusión; Datos de Prueba

En la tabla 1.21, se encuentra el desempeño de los clasificadores al utilizar los datos de prueba, donde el clasificador LDA cuenta con la menor tasa de error de 30%, seguido del Multilogit, y QDA, con 37%, y 47%, respectivamente, cosa contraria a lo que se presentó en los datos de entrenamiento.

Modelo Energía	Tasa de Precisión	Tasa de Error
LDA	70%	30%
QDA	53%	47%
Multilogit	63%	37%

Table 1.21: Desempeño de los clasificadores; Datos de Prueba

Red Neuronal

Para las Redes Neuronales, se realiza lo mismo que se hizo con la estimación de la disponibilidad; i.e., las mismas Redes Neuronales, con las mismas arquitecturas y el mismo trato a los datos de entrenamiento y de prueba. El gráfico 1.7, se presentan los criterios de selección de las Redes Neuronales, en el cual el gráfico de la izquierda sugiere la Red Neuronal 5 (la convulsionar); sin embargo, al utilizar una red más simple, en el gráfico de la derecha, se observa que una buena elección se encuentra entre la Red Neuronal 3 y 2, con un valor del error menor en la Red Neuronal 3, y un valor mayor en el criterio BIC, pero un menor valor en el AIC.

seleccionar el mejor bajo este criterio

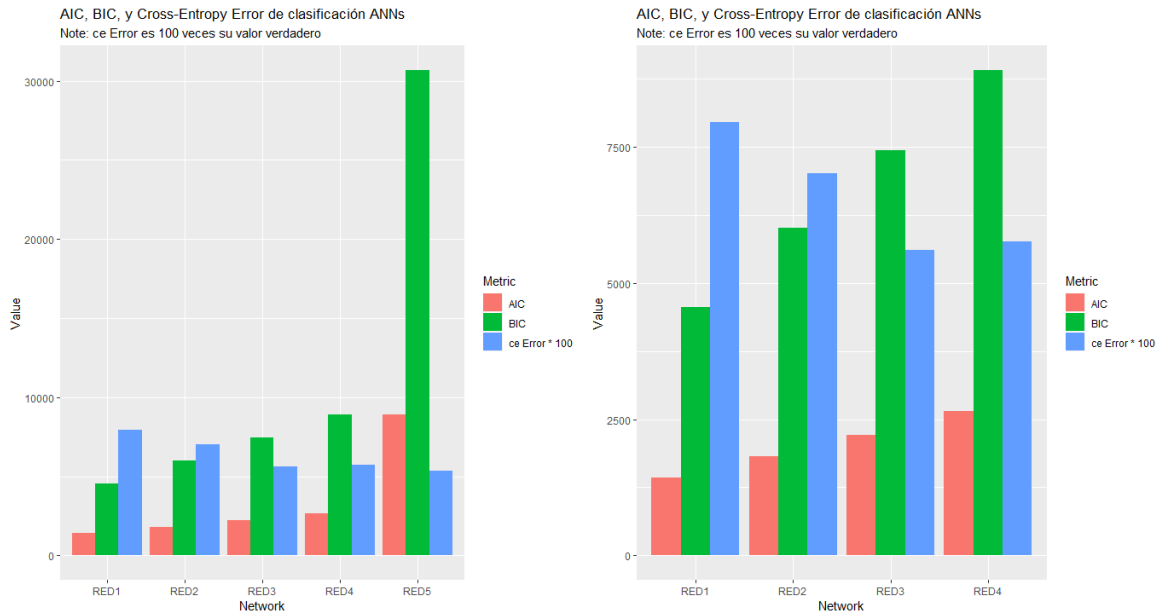


Figure 1.7: Criterios de selección de Red Neuronal

Para contrastar respecto a los otros, y contrastar los criterios previos, en la tabla 1.22, se presenta el desempeño de los clasificadores, al utilizar los datos de entrenamiento, y en base a lo anterior se puede ver que entre la Red Neuronal 2 y 3, la red 2 tiene una tasa de error menor que la red 3, de 6% y 7% respectivamente.

Modelo Energía	Tasa de Precisión	Tasa de Error
Red 1	92%	8%
Red 2	94%	6%
Red 3	93%	7%
Red 4	91%	9%
Red 5	93%	7%

Table 1.22: Desempeño de los clasificadores; Datos de Entrenamiento

Con lo anterior, se decide utilizar la Red Neuronal 2, cuya arquitectura consiste de 206 nodos de entradas, una capa oculta, 5 nodos ocultos, 3 nodos de salidas que miden las categoría de las pistas (energía baja, media y alta), y con función de activación logística (sigmoide); la Red Neuronal 2, se aprecia en la figura 1.8.

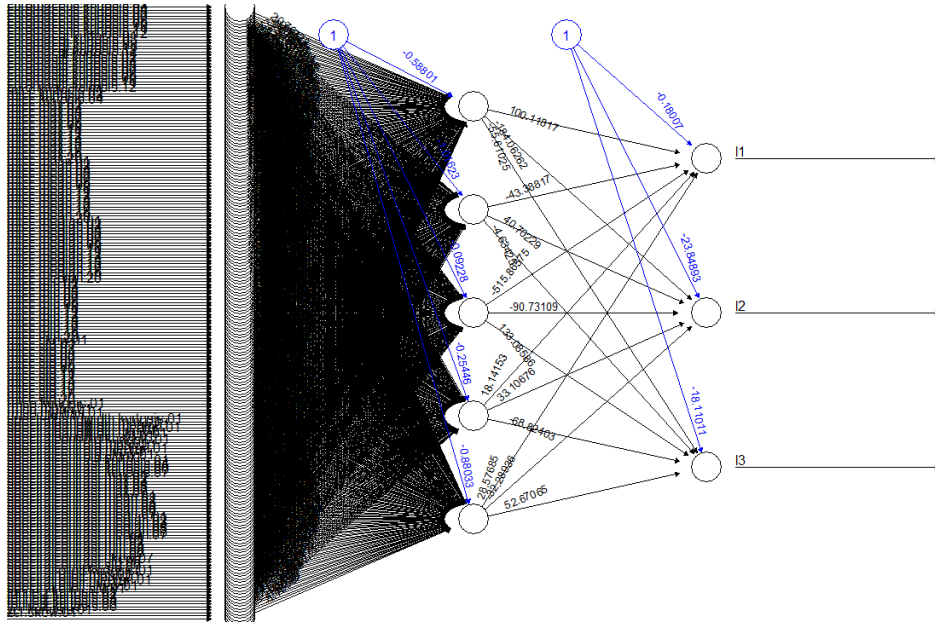


Figure 1.8: Red Neuronal 2

Se realiza el ajuste con los datos de entrenamiento, y en la tabla 1.23, se presenta la tabla de confusión en la clasificación de la energía en las pistas. En la tabla 1.24, se utilizan los datos de prueba para obtener la tabla de confusión, con la cual se observa que de 79% pistas con energía baja, la red clasifica 105%, de 85% pistas con energía media, clasifica 52%, y de 106%, con energía alta, clasifica 99%.

Predichos/ Originales	Bajo	Medio	Alto
Bajo	273	4	1
Medio	15	305	15
Alto	3	23	411

Table 1.23: Red Neuronal tabla de confusión; Datos de Entrenamiento

Predichos/ Originales	Bajo	Medio	Alto
Bajo	73	23	9
Medio	4	30	18
Alto	2	32	72

Table 1.24: Red Neuronal tabla de confusión; Datos de Prueba

La tabla 1.25, muestra la tasa de precisión y de error de la Red Neuronal 2, con una tasa de error del 67%. De esta manera, se concluye que de todos los clasificadores, los de menor error para estimar la clasificación de la energía son; el LDA y la Red Neuronal 2.

Modelo Energía	Tasa de Precisión	Tasa de Error
Red 2	67%	33%

Table 1.25: Desempeño de los clasificadores; Datos de Prueba

1.3 SOLUCIÓN INCISO "C"

Los ajustes de los clasificadores en el inciso "b", sirvieron de validación para la estimación del nivel de disponibilidad y energía para algún conjunto de audios tomados del archivo **my all track No genre 2019**. Para esto se verifica cualitativamente (se escuchan) los audios del subconjunto y se verifica si es adecuado la clasificación que realizan los clasificadores.

El trato que se le da a la base es la siguiente; la base previamente mencionada cuenta con 2231 fila y 531 observaciones, se realiza un filtrado en las variables para obtener aquellas con que se trabajaron los clasificadores, lo cual deja una base con 219 variables; de esta manera, se toma un subconjunto pequeño del 5% del total de los datos, que equivale a 112 observaciones.

Con la nueva base se utilizan los clasificadores que tuvieron mejor desempeño, medido con la menor tasa de error en clasificación; para estimar la disponibilidad de los audios se utiliza el clasificador LDA y la Red Neuronal 3 (con 6 nodos y una capa oculta); en el caso de la estimación de la energía en los audios, se utiliza el clasificador LDA y la Red Neuronal 2 (con 5 nodos y una capa oculta). No obstante, se realiza para los demás clasificadores, pero estos no son presentados en este documento, estas estimaciones y las demás se encuentran

en el archivo **Clasificación en Modelos.xlsx** que se junta con este trabajo.

Se realiza la clasificación utilizando todos los modelos, y se reportan los resultados de la estimación de la disponibilidad y energía en el archivo **xlsx**, mencionado en el párrafo anterior. Para no extender este documento, se presentan solo 10 audios extraídos de forma aleatoria del archivo **xlsx**; de esta manera, solo se presentan los resultados para esos audios, utilizando los modelos con mejor desempeño ya mencionados.

En la tabla 1.26, se presenta la tabla de clasificación cualitativa de los audios, con el fin de etiquetar las pistas cualitativamente en tres niveles de disponibilidad; la tabla contiene la clasificación que se le da de forma personal en base a escuchar los audios, donde 0 es disponibilidad baja, 1 disponibilidad Media y 2 disponibilidad alta; la tercera columna presenta el id de la pista, y la cuarta, el nombre del archivo.

Table 1.26: Clasificación Cualitativa Disponibilidad

Clasificación	Etiqueta	id.Pista	Nombre del Archivo
1	Medio	135871	fma_large/135/135871.mp3
0	Bajo	58226	fma_large/058/058226.mp3
1	Medio	57623	fma_large/057/057623.mp3
0	Bajo	67415	fma_large/067/067415.mp3
1	Medio	36270	fma_large/036/036270.mp3
1	Medio	149180	fma_large/149/149180.mp3
0	Bajo	79710	fma_large/079/079710.mp3
0	Bajo	76013	fma_large/076/076013.mp3
1	Medio	132438	fma_large/131/132438.mp3
0	Bajo	18152	fma_large/018/018152.mp3

En la tabla 1.27, se realiza lo mismo, pero ahora clasificando cualitativamente la pistas por su nivel de energía⁶.

⁶Es claro que las clasificación anterior puede ser no la mejora debido a el mal oído que tiene el clasificador.

Table 1.27: Clasificación Cualitativa Energía

Clasificación	Etiqueta	id.Pista	Nombre del Archivo
1	Medio	135871	fma_large/135/135871.mp3
0	Bajo	58226	fma_large/058/058226.mp3
1	Medio	57623	fma_large/057/057623.mp3
0	Bajo	67415	fma_large/067/067415.mp3
0	Bajo	36270	fma_large/036/036270.mp3
0	Bajo	149180	fma_large/149/149180.mp3
0	Bajo	79710	fma_large/079/079710.mp3
1	Alto	76013	fma_large/076/076013.mp3
0	Alto	132438	fma_large/131/132438.mp3
0	Bajo	18152	fma_large/018/018152.mp3

Estimación del nivel de Bailabilidad

Para la estimación de los niveles de bailabilidad se utiliza el clasificador LDA y la Red Neuronal 3, los otros clasificadores se encuentran en el apéndice del inciso "c". La tabla 1.28, presenta la estimación de la bailabilidad con el clasificador LDA, donde la columna Verdadero indica que el clasificador estimo el nivel de bailabilidad de acuerdo a la verificación cualitativa, y la columna Falso, indica lo contrario; de esta manera, con LDA se tiene 9 audios de 10, que coinciden con el nivel de bailabilidad del audio.

Table 1.28: Modelo LDA. Estimación de la bailabilidad

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
0	Bajo	135871	fma_large/135/135871.mp3		X
0	Bajo	58226	fma_large/058/058226.mp3	X	
1	Medio	57623	fma_large/057/057623.mp3	X	
0	Bajo	67415	fma_large/067/067415.mp3	X	
0	Bajo	36270	fma_large/036/036270.mp3	X	
0	Bajo	149180	fma_large/149/149180.mp3	X	
0	Bajo	79710	fma_large/079/079710.mp3	X	
1	Medio	76013	fma_large/076/076013.mp3	X	
1	Medio	132438	fma_large/131/132438.mp3	X	
0	Bajo	18152	fma_large/018/018152.mp3	X	

En la tabla 1.29, se tiene la estimación del nivel de bailabilidad con la Red Neuronal 3, donde se tiene que 5 audios de 10, coinciden con el nivel de bailabilidad de la pista.

Table 1.29: Modelo Red 3. Estimación de la bailabilidad

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
1	Medio	135871	fma_large/135/135871.mp3	X	
1	Medio	58226	fma_large/058/058226.mp3		X
1	Medio	57623	fma_large/057/057623.mp3	X	
1	Medio	67415	fma_large/067/067415.mp3		X
1	Medio	36270	fma_large/036/036270.mp3		X
1	Medio	149180	fma_large/149/149180.mp3		X
0	Bajo	79710	fma_large/079/079710.mp3	X	
1	Medio	76013	fma_large/076/076013.mp3		X
1	Medio	132438	fma_large/131/132438.mp3	X	
0	Bajo	18152	fma_large/018/018152.mp3	X	

Se concluye que para la estimación del nivel de bailabilidad, bajo el tratamiento que se le dieron a los datos y para esos diez audios, el clasificador LDA realiza una estimación adecuada.

Estimación del nivel de Energía

Para la estimación del nivel de la energía en los audios se utilizan los clasificadores LDA y la Red Neuronal 3. En la tabla 1.30, se presenta la estimación de nivel de energía en diez audios utilizando el clasificador LDA, donde se tiene que 7 audios de 10, coinciden con el nivel de energía que se le asigna a la pista.

Table 1.30: Modelo LDA. Estimación de la energía

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
0	Bajo	135871	fma_large/135/135871.mp3	X	
1	Medio	58226	fma_large/058/058226.mp3		X
1	Medio	57623	fma_large/057/057623.mp3	X	
0	Bajo	67415	fma_large/067/067415.mp3	X	
0	Bajo	36270	fma_large/036/036270.mp3	X	
0	Bajo	149180	fma_large/149/149180.mp3	X	
1	Medio	79710	fma_large/079/079710.mp3		X
2	Alto	76013	fma_large/076/076013.mp3	X	
1	Medio	132438	fma_large/131/132438.mp3		X
0	Bajo	18152	fma_large/018/018152.mp3	X	

En la tabla 1.31, se tiene la estimación del nivel de energía con la Red Neuronal 2, donde se tiene que 9 audios de 10, coinciden con el nivel de energía asignado a la pista de audio.

Table 1.31: Modelo Red 2. Estimación de la energía

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
0	Bajo	135871	fma_large/135/135871.mp3	X	
1	Medio	58226	fma_large/058/058226.mp3		X
1	Medio	57623	fma_large/057/057623.mp3	X	
0	Bajo	67415	fma_large/067/067415.mp3	X	
0	Bajo	36270	fma_large/036/036270.mp3	X	
0	Bajo	149180	fma_large/149/149180.mp3	X	
0	Bajo	79710	fma_large/079/079710.mp3	X	
2	Alto	76013	fma_large/076/076013.mp3	X	
2	Alto	132438	fma_large/131/132438.mp3	X	
0	Bajo	18152	fma_large/018/018152.mp3	X	

En conclusión, se tiene que para la estimación del nivel de energía, bajo el tratamiento que se le dieron a los datos y para los diez audios, la Red Neuronal 2 realiza una estimación adecuada.

1.4 APÉNDICE INCISO "C"

Estimación del nivel de Bailabilidad

Table 1.32: Modelo QDA. Estimación de la bailabilidad

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
1	Medio	135871	fma_large/135/135871.mp3	X	
1	Medio	58226	fma_large/058/058226.mp3		X
1	Medio	57623	fma_large/057/057623.mp3	X	
1	Medio	67415	fma_large/067/067415.mp3		X
1	Medio	36270	fma_large/036/036270.mp3		X
1	Medio	149180	fma_large/149/149180.mp3		X
1	Medio	79710	fma_large/079/079710.mp3		X
1	Medio	76013	fma_large/076/076013.mp3	X	
1	Medio	132438	fma_large/131/132438.mp3		X
1	Medio	18152	fma_large/018/018152.mp3	X	

Table 1.33: Modelo Mlogit. Estimación de la disponibilidad

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
1	Medio	135871	fma_large/135/135871.mp3	X	
0	Bajo	58226	fma_large/058/058226.mp3	X	
2	Alto	57623	fma_large/057/057623.mp3		X
0	Bajo	67415	fma_large/067/067415.mp3	X	
1	Medio	36270	fma_large/036/036270.mp3		X
1	Medio	149180	fma_large/149/149180.mp3		X
0	Bajo	79710	fma_large/079/079710.mp3	X	
1	Medio	76013	fma_large/076/076013.mp3		X
2	Alto	132438	fma_large/131/132438.mp3		X
0	Bajo	18152	fma_large/018/018152.mp3	X	

Table 1.34: Modelo Red 5 (Convulsionar). Estimación de la disponibilidad

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
1	Medio	135871	fma_large/135/135871.mp3	X	
0	Bajo	58226	fma_large/058/058226.mp3	X	
1	Medio	57623	fma_large/057/057623.mp3	X	
1	Medio	67415	fma_large/067/067415.mp3		X
1	Medio	36270	fma_large/036/036270.mp3		X
1	Medio	149180	fma_large/149/149180.mp3		X
1	Medio	79710	fma_large/079/079710.mp3		X
0	Bajo	76013	fma_large/076/076013.mp3		X
1	Medio	132438	fma_large/131/132438.mp3		X
1	Medio	18152	fma_large/018/018152.mp3	X	

Estimación del nivel de Energía

Table 1.35: Modelo QDA. Estimación de la energía

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
0	Bajo	135871	fma_large/135/135871.mp3	X	
2	Alto	58226	fma_large/058/058226.mp3		X
2	Alto	57623	fma_large/057/057623.mp3		X
1	Medio	67415	fma_large/067/067415.mp3		X
2	Alto	36270	fma_large/036/036270.mp3		X
1	Medio	149180	fma_large/149/149180.mp3		X
0	Bajo	79710	fma_large/079/079710.mp3	X	
2	Alto	76013	fma_large/076/076013.mp3	X	
2	Alto	132438	fma_large/131/132438.mp3	X	
0	Bajo	18152	fma_large/018/018152.mp3	X	

Table 1.36: Modelo Mlogit. Estimación de la energía

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
0	Bajo	135871	fma_large/135/135871.mp3	X	
1	Medio	58226	fma_large/058/058226.mp3		X
1	Medio	57623	fma_large/057/057623.mp3	X	
0	Bajo	67415	fma_large/067/067415.mp3	X	
0	Bajo	36270	fma_large/036/036270.mp3	X	
0	Bajo	149180	fma_large/149/149180.mp3	X	
1	Medio	79710	fma_large/079/079710.mp3		X
2	Alto	76013	fma_large/076/076013.mp3	X	
1	Medio	132438	fma_large/131/132438.mp3		X
0	Bajo	18152	fma_large/018/018152.mp3	X	

Table 1.37: Modelo Red 5 (Convulsionar). Estimación de la energía

Clasificación	Etiqueta	id.Pista	Nombre del Archivo	Verdadero	Falso
0	Bajo	135871	fma_large/135/135871.mp3	X	
2	Medio	58226	fma_large/058/058226.mp3		X
2	Medio	57623	fma_large/057/057623.mp3	X	
0	Bajo	67415	fma_large/067/067415.mp3	X	
0	Bajo	36270	fma_large/036/036270.mp3	X	
0	Bajo	149180	fma_large/149/149180.mp3	X	
0	Bajo	79710	fma_large/079/079710.mp3	X	
1	Medio	76013	fma_large/076/076013.mp3		X
2	Alto	132438	fma_large/131/132438.mp3	X	
0	Bajo	18152	fma_large/018/018152.mp3	X	